

ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΕΦΑΡΜΟΣΜΕΝΩΝ ΜΑΘΗΜΑΤΙΚΩΝ ΚΑΙ ΦΥΣΙΚΩΝ ΕΠΙΣΤΗΜΩΝ

Ανάλυση Δεδομένων με H/Y (6^ο εξάμηνο)

ΕΡΓΑΣΙΑ 1^η

Εισαγωγή στην R και Περιγραφική Στατιστική

Αικατερίνα Γεωργάνα

katgeorgana@gmail.com

ge20097@mail.ntua.gr

A.M: ge20097

Αθήνα, 03/04/2026

Άσκηση 1

Στη συγκεκριμένη στατιστική μελέτη ενδιαφερόμαστε για τον βαθμό επίδρασης των επεξηγηματικών μεταβλητών **Distance_km**, **Weather**, **Traffic_Level**, **Time_of_Day**, **Vehicle_Type**, **Preparation_Time_min**, **Courier_Experience_yrs** στην μεταβλητή απόκρισης **Delivery_Time_min**.


```
# Imports data in the form of a data frame
data<-read.csv(file = 
"/home/aikageor/Documents/semfe_semester_6/data_analysis/Food_Delivery_Times.csv ", head = TRUE, na.strings=c(""), stringsAsFactors = TRUE )
data
# TR is a logical vector
# Each element corresponds to a row in "data"
# TRUE → the row contains at least one NA
# FALSE → the row has no missing values
TR = apply(data,1,anyNA)
TR
# Returns the total number of rows that contain at least on NA
sum(TR)
# Use na.omit() to remove rows with missing values
clean_data<-na.omit(data)
clean_data
# Check: if sum(TR) = nrow(data) - nrow(data_final) then our
data set is ready
nrow(data) - nrow(clean_data)
sum(TR)
# Removing the column at index 1 (Order_ID)
final_data <- clean_data[, -1]
final_data
```

i.

```
> summary(final_data$Distance_km)
  Min. 1st Qu.  Median    Mean 3rd Qu.   Max.
  0.59   5.13   10.28   10.05   15.03   19.99
> par(mfrow=c(1,2))
> hist(final_data$Distance_km, probability = T, main = 'Histogram
of Distance_km', sub = 'Plot 1i.1' , xlab = 'Distance_km')
> boxplot(final_data$Distance_km, main = 'Boxplot of Distance_km',
sub = 'Plot 1i.2')
```

Από την εντολή **summary** που μας δίνει τα βασικότερα αριθμητικά μέτρα για την ποσοτική μεταβλητή **Distance_km** καθώς επίσης και από το ιστόγραμμα (**Plot 1i.1**) και το θηκόγραμμα (**Plot 1i.2**) τα οποία παρουσιάζονται ακριβώς από κάτω και προκύπτουν από τις παραπάνω εντολές, παρατηρούμε ότι οι αποστάσεις πελατών και καταστήματος είναι ομοιόμορφα κατανεμημένες μεταξύ των 0 και 20 χιλιομέτρων. Αναλυτικότερα από το θηκόγραμμα παρατηρούμε ότι η απόσταση της διαμέσου από το πρώτο τεταρτημόριο φαίνεται να είναι ίση με την απόσταση της ίδιας από το τρίτο τεταρτημόριο. Παρατηρείται συμμετρία στις ουρές, ενώ τα τεταρτημόρια είναι σχεδόν ίσα μεταξύ τους, χωρίζοντας το εύρος των τιμών σε τέσσερα σχεδόν ίσα μέρη. Παράλληλα,

στο ιστόγραμμα τα ύψη των παραλληλογράμμων, δεν εμφανίζουν ιδιαίτερη απόκλιση γεγονός που φανερώνει ότι η πιθανότητα εμφάνισης διαφορετικών τιμών χιλιομετρικής απόστασης είναι ομοιόμορφα κατανεμημένη.




Για τις κατηγορικές μεταβλητές **Weather** και **Traffic_Level** με τις παρακάτω εντολές μπορούμε να παρατηρήσουμε τις σχετικές συχνότητες σε κάθε κλάση.

```
> prop.table(table(final_data$Weather))
      Clear      Foggy      Rainy      Snowy      Windy
0.48131370 0.11098528 0.21291053 0.09739524 0.09739524
> prop.table(table(final_data$Traffic_Level))
      High      Low      Medium
0.2049830 0.3929785 0.4020385
```

Με τις παρακάτω εντολές κατασκευάζουμε ραβδογράμματα για τις μεταβλητές **Weather** (Plot 1i.3) και **Traffic_Level** (Plot 1i.4) αντίστοιχα.

```
> par(mfrow=c(1,2))
> WW<-prop.table(table(final_data$Weather))
> barplot(WW, main = "Weather barplot", sub = 'Plot 1i.3')
> TL<-prop.table(table(final_data$Traffic_Level))
> barplot(TL, main = "Traffic Level barplot", sub = 'Plot 1i.4')
```




Από τα παραπάνω αποτελέσματα για τις μεταβλητές **Weather** και **Traffic_Level** παρατηρείται ότι στο 50% των ημερών κατά τις οποίες πραγματοποιούνται παραγγελίες, οι καιρικές συνθήκες είναι καλές. Αντίθετα, στο 20% των ημερών καταγράφεται βροχόπτωση. Οι υπόλοιπες καιρικές συνθήκες εμφανίζονται με μικρότερη συχνότητα, καθώς χιονόπτωση, ομίχλη και έντονοι άνεμοι παρατηρούνται μόνο σε ποσοστό 10% το καθένα. Παράλληλα σε ποσοστό 80% τα επίπεδα κίνησης στους δρόμους είναι μέτρια ή χαμηλά, ενώ τις υπόλοιπες φορές παρατηρούνται υψηλότερα επίπεδα κυκλοφοριακής συμφόρησης.

Για τις κατηγορικές μεταβλητές **Time_of_Day** και **Vehicle_Type** με τις παρακάτω εντολές μπορούμε να παρατηρήσουμε τις σχετικές συχνότητες σε κάθε κλάση.

```
> prop.table(table(final_data$Time_of_Day))
Afternoon    Evening    Morning    Night
0.29105323  0.30464326  0.31823330  0.08607022
> prop.table(table(final_data$Vehicle_Type))
Bike    Car    Scooter
0.5107588 0.1947905 0.2944507
```

Με τις παρακάτω εντολές κατασκευάζουμε ραβδογράμματα για τις μεταβλητές **Time_of_Day** (**Plot 1i.5**) και **Vehicle_Type** (**Plot 1i.6**) αντίστοιχα.

```
> TD<-prop.table(table(final_data$Time_of_Day))
> barplot(TD, main = "Time_of_Day barplot", sub = 'Plot 1i.5')
> VT<-prop.table(table(final_data$Vehicle_Type))
> barplot(VT, main = "Vehicle_Type barplot", sub = 'Plot 1i.6')
```





Από τα παραπάνω αποτελέσματα για τις μεταβλητές **Time_of_Day** και **Vehicle_Type** διαπιστώνεται ότι περίπου το 30% των παραγγελιών πραγματοποιείται νωρίς το πρωί, ενώ παρόμοια είναι και τα ποσοστά παραγγελιών για το απόγευμα και το βράδυ. Αργά τη νύχτα παρατηρείται ότι συμβαίνει μόνο το 10% των παραγγελιών. Επιπλέον, οι παραγγελίες σε ποσοστό 50% παραδίδονται με ποδήλατο, σε ποσοστό περίπου 30% με σκούτερ ενώ οι υπόλοιπες με αυτοκίνητο.

Για την μεταβλητή **Preperation_Time_min**, υπολογίζουμε τα βασικότερα αριθμητικά μέτρα και κατασκευάζουμε το ιστόγραμμα (**Plot 1i_7**) και το θηκόγραμμα (**Plot 1i_8**) της με τις παρακάτω εντολές.

```
> summary(final_data$Preparation_Time_min)
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 5.00  11.00   17.00   17.02  23.00   29.00
```

```
> par(mfrow = c(1,2))
> hist(final_data$Preparation_Time_min, probability = T, main =
"Histogram of Preperation_Time_min", xlab =
'Preperation_Time_min', sub = 'Plot 1i.7')
> boxplot(final_data$Preparation_Time_min, main = 'Boxplot of
Preperation_Time_min',sub = 'Plot 1i.8' )
```



Ομοίως με την επεξηγηματική μεταβλητή **Distance_km** παρατηρούμε ότι και η μεταβλητή **Preperation_Time_min**, φαίνεται να είναι ομοιόμορφα κατανομημένη στο διάστημα 5 έως 30 λεπτά.

Για την μεταβλητή **Courier_Experience_yrs** υπολογίζουμε τα βασικότερα αριθμητικά μέτρα και κατασκευάζουμε το ιστόγραμμα (**Plot 1i_9**) και το θηκόγραμμα (**Plot 1i_10**) της με τις παρακάτω εντολές.

```
> summary(final_data$Courier_Experience_yrs)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.00   2.00   5.00   4.64   7.00   9.00


> par(mfrow = c(1,2))
> hist(final_data$Courier_Experience_yrs, probability = T, main =
"Histogram Courier_Experience_yrs", xlab =
'Courier_Experience_yrs' , sub = 'Plot 1i.9')
> boxplot(final_data$Courier_Experience_yrs, main = 'Boxplot of
Courire_Experience_yrs', sub = 'Plot 1i.10')
```



Για την ποσοτική μεταβλητή **Courier_Experience_yrs** παρατηρούμε κυρίως από το ιστόγραμμα το οποίο εικονίζεται παραπάνω, ότι το 20% των διανομέων έχει είτε μηδενική είτε το πολύ ένα χρόνο εργασιακή εμπειρία. Το υπόλοιπο 80% των διανομέων φαίνεται να είναι ομοιόμορφα κατανεμημένο, και έχει εργασιακή εμπειρία από ένα έως εννιά χρόνια.

Για την μεταβλητή **Delivery_Time_min** υπολογίζουμε τα βασικότερα αριθμητικά μέτρα και κατασκευάζουμε το ιστόγραμμα (*Plot 1i_11*) και το θηκόγραμμα (*Plot 1i_12*) της με τις παρακάτω εντολές.

```
> summary(final_data$Delivery_Time_min)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   8.00   41.00   55.00   56.43   71.00  141.00
> par(mfrow = c(1,2))
> hist(final_data$Delivery_Time_min, probability = T, main =
"Histogram of Delivery_Time_min", xlab = 'Delivery_Time_min', sub
= '1i.11')
> boxplot(final_data$Delivery_Time_min, main = 'Boxplot of
Delivery_Time_min', sub = '1i.12' )
```




Από τα παραπάνω διαγράμματα παρατηρούμε ότι ο χρόνος παράδοσης των παραγγελιών κυμαίνεται γύρω στα 50 λεπτά. Ωστόσο διαπιστώνεται ότι υπάρχουν ορισμένες ακραίες τιμές προς τα πάνω, οι οποίες αναπαριστούν κάποιες αρκετά μεγάλες καθυστερήσεις. Το γεγονός αυτό δημιουργεί ασυμμετρία στην κατανομή και πιο παχιές ουρές στην δεξιά μεριά της και κάνει την διάμεσο να απέχει λιγότερο από τον ελάχιστο χρόνο παράδοσης σε σχέση με τον μέγιστο.

ii.

```
> plot(final_data$Distance_km, final_data$Delivery_Time_min, pch
= 16, col = "green3", xlab = 'Distance_km', ylab =
"Delivery_Time_min", sub = 'Plot 1ii.1')
```

Με χρήση των παραπάνω εντολών θα κατασκευάσουμε ένα διάγραμμα το οποίο απεικονίζει τις τιμές της μεταβλητής **Delivery_Time_min** συναρτήσει των αντίστοιχων τιμών της μεταβλητής **Distance_km**. Από το *Plot 1ii_1* το οποίο προκύπτει και εικονίζεται ακριβώς από κάτω, διαπιστώνεται ότι ο χρόνος που απαιτείται για να παραδοθεί μία παραγγελία αυξάνεται γραμμικά σε σχέση με την χιλιομετρική απόσταση πελάτη και καταστήματος.





Για την σύγκριση των κλάσεων της **Weather** με τις τιμές της **Delivery_Time_min** και των κλάσεων της **Traffic_Level** με τις τιμές της **Delivery_Time_min** εφαρμόζουμε:

```
> par(mfrow = c(1,2))
```

```
> plot(final_data$Weather, final_data$Delivery_Time_min, xlab =  
'Weather' , ylab = 'Delivery_Time_min', sub = 'Plot 1ii.2')
```


```
> plot(final_data$Traffic_Level, final_data$Delivery_Time_min,  
xlab = 'Traffic_Level' , ylab = 'Delivery_Time_min', sub = 'Plot  
1ii.3')
```



Από το **Plot 1ii_2** που εικονίζεται παραπάνω, διαπιστώνεται ότι η διαφοροποίηση στον χρόνο παράδοσης των παραγγελιών δεν είναι σημαντική όταν ο καιρός είναι καλός, όταν βρέχει όταν έχει ομίχλη ή όταν φυσάει. Ωστόσο παρατηρείται καθυστέρηση περίπου είκοσι λεπτών στον χρόνο παράδοσης της παραγγελίας όταν χιονίζει. Από το **Plot 1ii_3** παρατηρείται ότι δεν υπάρχει σημαντική διαφορά στην χρόνο παράδοσης των παραγγελιών όταν τα επίπεδα κίνησης στους δρόμους είναι χαμηλά ή μέτρια, ωστόσο υπάρχει αύξηση περίπου δεκαπέντε λεπτών όταν τα επίπεδα κίνησης είναι υψηλά.

Για την σύγκριση των κλάσεων της **Time_of_Day** με τις τιμές της **Delivery_Time_min** και των κλάσεων της **Vehicle_Type** με τις τιμές της **Delivery_Time_min** εφαρμόζουμε:

```
> par(mfrow = c(1,2))
> plot(final_data$Time_of_Day, final_data$Delivery_Time_min, xlab = 'Time_of_Day' , ylab = 'Delivery_Time_min', sub = 'Plot 1ii.4')
> plot(final_data$Vehicle_Type, final_data$Delivery_Time_min, xlab = 'Vehicle_Type' , ylab = 'Delivery_Time_min', sub = 'Plot 1ii.5')
```





Από το **Plot 1ii_4** που εικονίζεται παραπάνω παρατηρείται ότι δεν υπάρχει ιδιαίτερη διαφοροποίηση στον χρόνο παράδοσης της παραγγελίας ανάλογα με τις διαφορετικές χρονικές περιόδους της ημέρας, εκτός ίσως από ορισμένες ακραίες καθυστερήσεις που φαίνεται να συμβαίνουν αργά το απόγευμα. Επιπλέον διαπιστώνεται ότι τη νύχτα υπάρχει μία μικρή μείωση μεταξύ πέντε και δέκα λεπτών στον χρόνο παράδοσης. Αντίστοιχα από το **Plot 1ii_5** παρατηρείται ότι δεν υπάρχει σημαντική διαφοροποίηση στον χρόνο παράδοσης των παραγγελιών είτε αυτές πραγματοποιούνται με ποδήλατο, είτε με αυτοκίνητο, είτε με σκούτερ.

Για την σύγκριση των τιμών της **Preperation_Time_min** με τις τιμές της **Delivery_Time_min** και των τιμών της **Courier_Experience_yrs** με τις αντίστοιχες τιμές της **Delivery_Time_min** εφαρμόζουμε:

```
> par(mfrow = c(1,2))
> plot(final_data$Preperation_Time_min, final_data$Delivery_Time_min, xlab = 'Preperation_Time_min' , ylab = 'Delivery_Time_min', pch = 20, col = 'red', sub = 'Plot 1ii.6')
```



```
> plot(final_data$Courier_Experience_yrs,
final_data$Delivery_Time_min, xlab = 'Courier_Experience_yrs' ,
ylab = 'Delivery_Time_min', pch = 20 , col = 'green', sub = 'Plot
1ii.7')
```



Το **Plot 1ii_6** το οποίο προκύπτει από τις παραπάνω εντολές και εικονίζεται παραπάνω, φανερώνει ότι υπάρχει μία γραμμική αύξηση του χρόνου παράδοσης των παραγγελιών σε σχέση με την αύξηση του χρόνου προετοιμασίας των παραγγελιών. Αντιθέτως στο **Plot 1ii_6** παρατηρείται ότι ο χρόνος παράδοσης της παραγγελίας δεν φαίνεται να έχει σχέση με την εμπειρία των διανομέων στο επάγγελμα, αφού υπάρχει σχετική ομοιομορφία στους χρόνους παράδοσης των παραγγελιών είτε αυτές παραδίδονται από έμπειρους διανομείς είτε όχι.

iii.

```
# Convert to factor first because it is numeric
final_data$f_Courr <- as.factor(final_data$Courier_Experience_yrs)
levels(final_data$f_Courr) <- list("0-3_yrs_of_exp" = c("0", "1",
"2", "3"), "4-6_yrs_of_exp" = c("4", "5", "6"), "7-9_yrs_of_exp" =
c("7", "8", "9"))
> table(final_data$f_Courr)
0-3_yrs_of_exp 4-6_yrs_of_exp 7-9_yrs_of_exp
          336             268             279
> prop.table(table(final_data$f_Courr))
0-3_yrs_of_exp 4-6_yrs_of_exp 7-9_yrs_of_exp
    0.3805210    0.3035108    0.3159683
q1 <- quantile(final_data$Preparation_Time_min, 0.25)
q2 <- quantile(final_data$Preparation_Time_min, 0.50)
q3 <- quantile(final_data$Preparation_Time_min, 0.75)
> q1
25%
11
```

```
> q2
50%
17
> q3
75%
23
```

```
final_data$f_PR <- as.factor(
  ifelse(final_data$Preparation_Time_min < q1, "[0 min, q1 = 11
min)",
        ifelse(final_data$Preparation_Time_min < q2, "[q1 = 11
min, q2 = 17 min)",
        ifelse(final_data$Preparation_Time_min < q3, "[q2
= 17 min , q3 = 23 min )",
        "[q3 = 23 min,...)"))))
```

Για την κατασκευή του δισδιάστατου πίνακα συχνοτήτων των μεταβλητών **f_PR** και **f_Courr** εφαρμόζουμε τις παρακάτω εντολές.

```
> mytable <- table(final_data$f_PR, final_data$f_Courr)
> mytable
```

	0-3_yrs_of_exp	4-6_yrs_of_exp	7-9_yrs_of_exp
[0 min, q1 = 11 min)	86	63	71
[q1 = 11 min, q2 = 17 min)	73	66	71
[q2 = 17 min , q3 = 23 min)	76	64	63
[q3 = 23 min,...)	101	75	74

Για τις σχετικές συχνότητες των κελιών εφαρμόζουμε τα παρακάτω

```
> prop.table(mytable)
```


	0-3_yrs_of_exp	4-6_yrs_of_exp	7-9_yrs_of_exp
[0 min, q1 = 11 min)	0.09739524	0.07134768	0.08040770
[q1 = 11 min, q2 = 17 min)	0.08267271	0.07474519	0.08040770
[q2 = 17 min , q3 = 23 min)	0.08607022	0.07248018	0.07134768
[q3 = 23 min,...)	0.11438279	0.08493771	0.08380521

Από τον παραπάνω πίνακα που προέκυψε για τις σχετικές συχνότητες των κελιών των μεταβλητών **f_PR** και **f_Courr** παρατηρούμε ότι:

- Το 9.74% των παραγγελιών παραδόθηκαν από διανομείς με προϋπηρεσία στην ίδια θέση από μηδέν έως τρία έτη και έφτασαν στον παραλήπτη τους σε λιγότερα από 11 λεπτά.
- Το 7.13% και 8.04% των παραγγελιών παραδόθηκαν επίσης σε λιγότερο από 11 λεπτά από διανομείς με τέσσερα έως έξι και επτά έως εννέα χρόνια προϋπηρεσίας αντίστοιχα.
- Το 8.27% των παραγγελιών παραδόθηκαν από διανομείς με προϋπηρεσία στην ίδια θέση από μηδέν έως τρία έτη και έφτασαν στον παραλήπτη τους σε χρόνο μεγαλύτερο των 11 και μικρότερο των 17 λεπτών.
- Το 8.38% των παραγγελιών έφτασαν στον προορισμό τους μετά από τουλάχιστον 23 λεπτά, παρόλο που οι διανομείς οι οποίοι τις μετέφεραν είχαν επτά με εννέα χρόνια προϋπηρεσία στην ίδια θέση.

Ομοίως είναι δυνατή η ερμηνεία όλων των κελιών του παραπάνω πίνακα σχετικών συχνοτήτων.

```
> barplot(mytable, col = 1:4, legend=levels(final_data$f_PR), xlim = c(0, 6), main = 'Stacked barplot of contingency table', xlab = "Courier_Experience_yrs" , ylab = 'Number_of_orders', sub = 'Plot 1iii.1')
```



Το συγκεκριμένο στοιβαγμένο ραβδόγραμμα που προκύπτει από τις παραπάνω εντολές, απεικονίζει γραφικά τα κατηγορικά δεδομένα που προέρχονται από τις δύο μεταβλητές **f_PR** και **f_Courr**. Ουσιαστικά μας δίνει την δυνατότητα αναπαράστασης των από κοινού συχνοτήτων των κατηγοριών μεταβλητών, των στοιχείων δηλαδή του πίνακα **mytable** τον οποίο βρήκαμε νωρίτερα. Αναλυτικότερα με μαύρο χρώμα αποτυπώνεται το πλήθος των παραγγελιών που παραδόθηκαν σε χρόνο λιγότερο από 11 λεπτά από διανομείς με 0-3 με 4-6 και με 7 ή περισσότερα χρόνια εμπειρίας αντίστοιχα σε ξεχωριστές για την κάθε κλάση στήλες. Ομοίως για τα υπόλοιπα χρώματα του διαγράμματος. Αξίζει να υπογραμμίσουμε το γεγονός ότι δεν υπάρχει σημαντική διαφοροποίηση στις από κοινού συχνότητες για τους διανομείς με 4-6 και 7-9 χρόνια εμπειρίας. Ωστόσο δεν πρέπει να παραλείψουμε να τονίσουμε ότι αισθητή είναι η διαφοροποίηση στις από κοινού συχνότητες για τους άπειρους διανομείς, αφού παρατηρούμε μεγαλύτερο αριθμό παραγγελιών να παραδίδονται σε χρονικό διάστημα μεγαλύτερο των 23 λεπτών.

Άσκηση 2

β)

Αρχικά κατασκευάζουμε δύο συναρτήσεις οι οποίες να υπολογίζουν την διάμεσο και την μέση τιμή αντίστοιχα ενός διανύσματος. Κατόπιν επαληθεύουμε ότι επιστρέφουν τα σωστά αποτελέσματα, διασταυρώνοντάς τα με αυτά τα οποία προκύπτουν από την χρήση των έτοιμων εντολών της R **mean()** και **median()**. Ελέγχουμε την ορθότητα των συναρτήσεων που κατασκευάσαμε για διανύσματα άρτιου και περιττού μήκους.

```
# Function for median value calculation
find_median <- function(x) {
  x <- sort(x)
  n <- length(x)
  if (n %% 2 != 0) {
    # Odd vector length
    return(x[(n + 1) / 2])
  } else {
    # Even vector length
    return((x[n / 2] + x[n / 2 + 1]) / 2)
  }
}

# Check for a random vector with even length
# If find_median(x) = median(x) our function is correct, otherwise
is wrong
x <- c(1, 2, 3, 4)
find_median(x)
median(x)
# Check for a random vector with odd length
# If find_median(x) = median(x) our function is correct, otherwise
is wrong
x <- c(1, 2, 3)
find_median(x)
median(x)
Και προκύπτουν τα παρακάτω αποτελέσματα:
> # Function for median value calculation
> find_median <- function(x) {
+   x <- sort(x)
+   n <- length(x)
+   if (n %% 2 != 0) {
+     # Odd vector length
+     return(x[(n + 1) / 2])
+   } else {
+     # Even vector length
+     return((x[n / 2] + x[n / 2 + 1]) / 2)
+   }
+ }
>
> # Check for a random vector with even length
> # If find_median(x) = median(x) our function is correct,
otherwise is wrong
```

```

> x <- c(1, 2, 3, 4)
> find_median(x)
[1] 2.5
> median(x)
[1] 2.5
>
> # Check for a random vector with odd length
> # If find_median(x) = median(x) our function is correct,
otherwise is wrong
> x <- c(1, 2, 3)
> find_median(x)
[1] 2
> median(x)
[1] 2

# Function for mean value calculation
find_mean <- function(x) {

  return(sum(x)/length(x))

}

# Check for a random vector
# If find_mean(x) = mean(x) our function is correct, otherwise is
wrong
x <- c(1, 2, 3)
find_mean(x)
mean(x)
Και προκύπτουν τα παρακάτω αποτελέσματα:
> # Function for mean value calculation
> find_mean <- function(x) {
+
+   return(sum(x)/length(x))
+
+ }
>
> # Check for a random vector
> # If find_mean(x) = mean(x) our function is correct, otherwise
is wrong
> x <- c(1, 2, 3)
> find_mean(x)
[1] 2
> mean(x)
[1] 2

Με τον τρόπον αυτό διαπιστώνουμε ότι οι συναρτήσεις οι οποίες κατασκευάσαμε δίνουν ορθά
αποτελέσματα. Στόχος μας είναι να μπορέσουμε να τις καλέσουμε αργότερα μέσα στην
myvectorsummary. Για την κατασκευή της ζητούμενης συνάρτησης εφαρμόζουμε τα παρακάτω:

# Function myvectorsummary
# Inputs: vec <- c(a, b, c, ... ) a numerical vector and
logical_value == TRUE OR FALSE

```

```

myvectorsummary <- function(vec, logical_value){
  if(any(is.na(vec)) == TRUE & logical_value == FALSE)
  {
    no_na_vec <- vec[!is.na(vec)] # Removes the NAs from the input
vector
    return(list("missing values", find_median(no_na_vec)) )
  } else if(any(is.na(vec)) == TRUE & logical_value == TRUE)
  {
    no_na_vec <- vec[!is.na(vec)] # Removes the NAs from the input
vector
    return(list("missing values", data.frame(median_value =
find_median(no_na_vec), mean_value = find_mean(no_na_vec) )))
  } else if(any(is.na(vec)) == FALSE & logical_value == FALSE)
  {
    return(list("no missing values", find_median(vec)) )
  } else
  {
    return(list("no missing values", data.frame(median_value =
find_median(vec), mean_value = find_mean(vec) )))
  }
}

```

Υλοποιούμε την παραπάνω συνάρτηση για τα ζητούμενα διανύσματα και προκύπτουν τα παρακάτω:

```

> x <- c(NA, 1, 3, 4, 5)
> myvectorsummary(x, FALSE)
[[1]]
[1] "missing values"

[[2]]
[1] 3.5

> myvectorsummary(x, TRUE)
[[1]]
[1] "missing values"

[[2]]
  median_value mean_value
1          3.5         3.25
> z <- c(3, 4, 5, 6 ,7)
> myvectorsummary(z, FALSE)
[[1]]
[1] "no missing values"

[[2]]
[1] 5

> myvectorsummary(z, TRUE)
[[1]]
[1] "no missing values"

```

```

[[2]]
  median_value mean_value
1           5           5
> h <- c (4, 5, 1, 2)
> myvectorsummary(h, FALSE)
[[1]]
[1] "no missing values"

```

```

[[2]]
[1] 3

```

```

> myvectorsummary(h, TRUE)
[[1]]
[1] "no missing values"

```

```

[[2]]
  median_value mean_value
1           3           3

```

a)

```

Game <- function (players_life){

  i <- 0 # i: the number of rounds played
  total_pd <- 0 # total damage done by the player

  while(players_life > 0)
  {
    pd = sample(10:12, 1) # damage done by the player in the round
    # print(pd) # we can remove the comment if we want to see the
value that was generated
    gd = sample(4:6, 1) # damage done by the giant in the round
    # print(gd) # we can remove the comment if we want to see the
value that was generated
    y = rbinom(1, size=1, prob=0.1)
    # print(y) # we can remove the comment if we want to see the
value that was generated
    if ( y == 1)
    {
      gd <- gd*2
    } else
    {
      gd <- gd
    }
    i <- i + 1
    total_pd <- total_pd + pd
    players_life <- players_life - gd
  }
  score <- total_pd * (i-1)

```

```
return(list(  
  total_damage = total_pd,  
  rounds = i,  
  score = score))}
```